Veri Setinin Yüklenmesi

In [1]:
```
import numpy as np
import pandas as pd

panel = pd.read_csv(
    "panel.csv",
    parse_dates=["month"],   # month datetime olarak gelsin
    dtype={
        "loan_id": "int32",
        "customer_id": "int32",
        "credit_history_months": "int16",
        "product_count": "int16",
        "salary_customer": "int8",
        "term_months": "int8",
        "past_due_30d_count": "int16",
        "default_12m": "int8"
    }
)
```

Exploratory Data Analysis (EDA)

Bu bölümde veri setinin temel yapısı, değişken dağılımları, veri tipleri, eksik değer durumu ve hedef değişkenin genel görünümü incelenmiştir. Amaç, model kurulumundan önce veri kalitesini ve değişkenlerin temel davranışlarını anlamaktır.

In [2]:
```
panel.describe(include="all").T
```

Out[2]:

	count	mean	min	25%	50%	75%	max	
loan_id	432000.0	9000.5	1.0	4500.75	9000.5	13500.25	18000.0	5196.15
customer_id	432000.0	5966.214389	1.0	2994.75	5961.0	8950.25	12000.0	3454.99
income	432000.0	39071.765942	6085.057086	25998.974133	35146.989916	47749.148416	226649.934899	18560.36
credit_history_months	432000.0	92.152833	6.0	49.0	92.0	135.0	179.0	50.17
product_count	432000.0	2.332278	1.0	1.0	2.0	3.0	10.0	1.35
salary_customer	432000.0	0.450444	0.0	0.0	0.0	1.0	1.0	0.49
loan_amount	432000.0	216042.424749	18272.095381	119957.378132	179474.081368	269505.589602	1757913.819445	143721.47
term_months	432000.0	28.756667	12.0	24.0	24.0	36.0	48.0	11.65
interest_rate	432000.0	24.325416	13.390204	21.989171	23.918631	26.073696	55.0	3.50
dti	432000.0	0.264504	0.02	0.120275	0.253056	0.385275	0.95	0.17
utilization	432000.0	0.362271	0.01	0.190652	0.352923	0.516499	0.99	0.22
month	432000	2024-12-15 22:00:00.000001024	2024-01-01 00:00:00	2024-06-23 12:00:00	2024-12-16 12:00:00	2025-06-08 12:00:00	2025-12-01 00:00:00	
cpi_yoy	432000.0	44.102578	42.31543	43.546961	44.303785	44.605565	45.764599	0.82
policy_rate	432000.0	36.020656	34.609769	35.621267	36.197939	36.513212	37.13524	0.68
unemployment	432000.0	8.920392	8.557097	8.764185	8.943559	9.048405	9.33338	0.19
digital_activity_score	432000.0	60.580583	8.641346	52.7559	60.478769	68.292958	100.0	11.48
last_3m_spend	432000.0	16824.130815	0.0	13816.658654	16756.664266	19752.364154	44199.711313	4444.12
past_due_30d_count	432000.0	0.918928	0.0	0.0	1.0	1.0	10.0	1.05
default_12m	432000.0	0.259285	0.0	0.0	0.0	1.0	1.0	0.43
lgd	432000.0	0.355572	0.01	0.231006	0.340431	0.464577	0.99	0.17

In [3]:
```
panel.head(50)
```

Out[3]:

	loan_id	customer_id	income	credit_history_months	product_count	salary_customer	loan_amount	term_months	interest_rate
0	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
1	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
2	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
3	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
4	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
5	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
6	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
7	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
8	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
9	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
10	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
11	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
12	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
13	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
14	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
15	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
16	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
17	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
18	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
19	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
20	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
21	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
22	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
23	1	9861	87942.308585	33	1	1	258749.553241	24	23.809806
24	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
25	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
26	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
27	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
28	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
29	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
30	2	700	34616.994883	11	2	1	314912.611697	24	28.004946

	loan_id	customer_id	income	credit_history_months	product_count	salary_customer	loan_amount	term_months	interest_rate
31	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
32	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
33	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
34	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
35	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
36	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
37	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
38	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
39	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
40	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
41	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
42	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
43	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
44	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
45	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
46	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
47	2	700	34616.994883	11	2	1	314912.611697	24	28.004946
48	3	10269	65637.402242	58	1	1	92451.877035	48	24.166747
49	3	10269	65637.402242	58	1	1	92451.877035	48	24.166747

İlk gözlemler incelendiğinde veri setinin kredi-ay düzeyinde panel yapıda olduğu görülmektedir. Aynı kredi farklı aylarda tekrar gözlemleniyor, bu sayede zaman boyutunda risk analizi yapılabiliriz.

Veri Kalitesi ve Yapısal Kontroller

In [4]:
```
print("panel.shape =", panel.shape)
```

```
panel.shape = (432000, 20)
```

In [5]:
```
display(panel.dtypes)
```

```
loan_id                           int32
customer_id                       int32
income                          float64
credit_history_months             int16
product_count                     int16
salary_customer                    int8
loan_amount                     float64
term_months                        int8
interest_rate                   float64
dti                             float64
utilization                     float64
month                     datetime64[ns]
cpi_yoy                         float64
policy_rate                     float64
unemployment                    float64
digital_activity_score          float64
last_3m_spend                   float64
past_due_30d_count                int16
default_12m                        int8
lgd                             float64
dtype: object
```

In [6]:
```
display(panel.isna().mean().sort_values(ascending=False).head(10)) #N/A değerler var mı baktık.
```

```
loan_id                  0.0
customer_id              0.0
default_12m              0.0
past_due_30d_count       0.0
last_3m_spend            0.0
digital_activity_score   0.0
unemployment             0.0
policy_rate              0.0
cpi_yoy                  0.0
month                    0.0
dtype: float64
```

In [7]:
```
(panel == 0).mean().sort_values(ascending=False) #Sayısal değişkenlerde sıfır değer yoğunluğunu inceliyoruz. Bu kontrol özelli
```

Out[7]:
```
default_12m              0.740715
salary_customer          0.549556
past_due_30d_count       0.435368
last_3m_spend            0.000069
loan_id                  0.000000
month                    0.000000
digital_activity_score   0.000000
unemployment             0.000000
policy_rate              0.000000
cpi_yoy                  0.000000
utilization              0.000000
customer_id              0.000000
dti                      0.000000
interest_rate            0.000000
term_months              0.000000
loan_amount              0.000000
product_count            0.000000
credit_history_months    0.000000
income                   0.000000
lgd                      0.000000
dtype: float64
```

In [8]:
```
print("default_12m rate= =", panel["default_12m"].mean())  # Default olanların oranını çıkardık.
```

```
default_12m rate= = 0.2592847222222222
```

Korelasyon Analizi

In [9]:
```
corr = panel.corr(numeric_only=True)["default_12m"].sort_values(ascending=False) # Bağımlı değişkenimizin bağımsız değişkenler
print(corr.head(19))
```

```
default_12m               1.000000
dti                       0.344291
utilization               0.340763
lgd                       0.290000
past_due_30d_count        0.261584
last_3m_spend             0.016098
policy_rate               0.003129
loan_id                   0.002141
unemployment              0.001518
cpi_yoy                   0.000343
term_months              -0.000761
customer_id              -0.002169
credit_history_months    -0.003159
interest_rate            -0.004400
loan_amount              -0.006330
digital_activity_score   -0.023546
salary_customer          -0.032823
product_count            -0.039615
income                   -0.063124
Name: default_12m, dtype: float64
```

Korelasyon sonuçlarına göre dti, utilization ve past_due_30d_count değişkenleri hedef değişken ile en güçlü pozitif ilişkiye sahip görünmekte. income, product_count ve salary_customer ise negatif yönlü ilişki göstermekte. Ancak korelasyon analizi yalnızca doğrusal ilişkiyi gösterdiğinden değişkenlerin modele katkısı nihai olarak lojistik regresyon çıktıları ile değerlendirilecek.

Not: Korelasyon testi sonucu LGD değişkeninin bağımlı değişkenimiz ile belirli düzeyde ilişki gösterdiği görülüyor. Ancak LGD temerrüt gerçekleştikten sonra ortaya çıkan bir risk parametresi olduğundan PD modelinde bağımsız değişken olarak kullanılmayacak. PD, LGD ve EAD bankacılık risk modellemesinde ayrı parametreler olarak modellenir.

Cut-off + Train/Test Ayrımı

In [10]:
```
panel_sorted = panel.sort_values("month") # Veriyi eskiden yeniye sıralarız
```

In [11]:
```
cutoff = panel_sorted["month"].max() - pd.offsets.MonthBegin(4)
```

In [12]:
```
print(cutoff)
```

```
2025-08-01 00:00:00
```

In [13]:
```
print(panel_sorted["month"].max(), panel_sorted["month"].min())  # Veriseti tarih aralığı kontrolü
```

```
2025-12-01 00:00:00 2024-01-01 00:00:00
```

In [14]:
```
# Eğitim veriseti için
train = panel_sorted[panel_sorted["month"] < cutoff].copy()
```

In [15]:
```
# Test veriseti için
test = panel_sorted[panel_sorted["month"] >= cutoff].copy()
```

In [16]:
```
print("Train months:", train["month"].min(), "->", train["month"].max(), " | n=", len(train))
print("Test  months:", test["month"].min(),  "->", test["month"].max(),  " | n=", len(test))
```

```
Train months: 2024-01-01 00:00:00 -> 2025-07-01 00:00:00  | n= 342000
Test  months: 2025-08-01 00:00:00 -> 2025-12-01 00:00:00  | n= 90000
```

Veri seti zaman boyutu içerdiği için rastgele train-test ayrımı yerine kronolojik ayrım tercih ettik. Böylece model geçmiş dönem verileri üzerinden eğitilip, sonraki dönem performansı ise out of time validation yaklaşımıyla test edilir.

Modelde Kullanılacak Değişkenlerin Belirlenmesi

In [17]:
```
import statsmodels.api as sm
```

In [18]:
```
features = [
    "dti",
    "utilization",
    "past_due_30d_count",
    "income",
    "salary_customer",
    "product_count",
    "policy_rate",
    "unemployment",
    "cpi_yoy"
]
# Logit modelinde tüm değişkenler değil, ekonomik olarak güçlü ve yorumlanabilir çekirdek risk driver'ları seçilir.
# Korelasyonlu değişkenler tamamen dışlanmaz; farklı ekonomik hikaye taşıyorlarsa birlikte tutulabilir. Ancak yüksek korelasyo
```

Çoklu Doğrusal Bağlantı

Modelde kullanacağımız bağımsız değişkenleri belirledikten sonra, bu değişkenler arasında çoklu doğrusal bağlantı olup olmadığını kontrol etmek için varyans şişirme faktörü (VIF) uygularız. Analiz yalnızca eğitim veri seti üzerinde gerçekleştirilerek veri sızıntısı (data leakage) önlenir.

In [19]:
```
from statsmodels.stats.outliers_influence import variance_inflation_factor
import pandas as pd
import statsmodels.api as sm

X = train[features]
X = sm.add_constant(X)

vif = pd.DataFrame()
vif["variable"] = X.columns
vif["VIF"] = [
    variance_inflation_factor(X.values, i)
    for i in range(X.shape[1])
]

vif
```

Out[19]:

	variable	VIF
0	const	17775.483514
1	dti	3.142236
2	utilization	3.149121
3	past_due_30d_count	1.148748
4	income	1.000343
5	salary_customer	1.000142
6	product_count	1.000315
7	policy_rate	1.703573
8	unemployment	1.528162
9	cpi_yoy	1.330083

Analiz sonuçlarına göre tüm değişkenlerin VIF değerleri kabul edilebilir seviyelerde (VIF < 5) bulunmuş olup modelde önemli bir multicollinearity (ÇDB) problemi tespit edilmemiştir. DTI ve utilization değişkenlerinin VIF değerleri diğer değişkenlere göre daha yüksek olsa da bu durum ekonomik olarak beklenmektedir ve modelin istatistiksel stabilitesini bozacak bir durum değildir.

Lojistik Regresyon Modeli

In [20]:
```
x_train = train[features]
y_train = train["default_12m"]
```

In [21]:
```
x_train_const = sm.add_constant(x_train) # alternatif tek seferde: x_train = sm.add_constant(train[features])
```

In [22]:
```
logit_model = sm.Logit(y_train, x_train_const) # Logit modeli tanımladık
```

In [23]:
```
# sm.Logit her müşteri için: 0 ile 1 arasında default olasılığı üretir.
```

In [24]:
```
logit_res = logit_model.fit(disp=False) #fit edildi train edildi
```

In [25]:
```
logit_res.summary()
```

Out[25]:

Logit Regression Results

Dep. Variable:	default_12m	**No. Observations:**	342000
Model:	Logit	**Df Residuals:**	341990
Method:	MLE	**Df Model:**	9
Date:	Mon, 16 Mar 2026	**Pseudo R-squ.:**	0.1402
Time:	04:58:09	**Log-Likelihood:**	-1.6811e+05
converged:	True	**LL-Null:**	-1.9552e+05
Covariance Type:	nonrobust	**LLR p-value:**	0.000

	coef	std err	z	P>|z|	[0.025	0.975]
const	-3.6492	0.568	-6.422	0.000	-4.763	-2.535
dti	2.3640	0.041	57.290	0.000	2.283	2.445
utilization	1.7410	0.033	52.863	0.000	1.676	1.806
past_due_30d_count	0.3363	0.004	83.289	0.000	0.328	0.344
income	-1.005e-05	2.45e-07	-41.065	0.000	-1.05e-05	-9.57e-06
salary_customer	-0.1909	0.009	-22.149	0.000	-0.208	-0.174
product_count	-0.0815	0.003	-25.322	0.000	-0.088	-0.075
policy_rate	0.0238	0.009	2.718	0.007	0.007	0.041
unemployment	0.0678	0.027	2.536	0.011	0.015	0.120
cpi_yoy	0.0011	0.006	0.191	0.849	-0.010	0.012

İlk model sonuçlarına göre dti, utilization ve past_due_30d_count değişkenleri temerrüt olasılığını artıran anlamlı risk faktörleri olarak öne çıkıyor. income, salary_customer ve product_count değişkenleri ise beklenen şekilde koruyucu yönde çalışmaktadır (ilgili değişken arttıkça temerrüt olasılığı azalır). cpi_yoy değişkeni bu spesifikasyonda istatistiksel olarak anlamlı değildir.

Robust Standart Hatalar

In [26]:
```
# Heteroskedasiteye karşı daha güvenilir standart hata, p-value ve güven aralığı elde edelim.
```

In [27]:
```
logit_res_robust = logit_model.fit(disp="False", cov_type="HC1") #train edilen model robust tanımlandı
logit_res_robust.summary()
```

```
Optimization terminated successfully.
         Current function value: 0.491545
         Iterations 6
```

Out[27]:

Logit Regression Results

Dep. Variable:	default_12m	**No. Observations:**	342000
Model:	Logit	**Df Residuals:**	341990
Method:	MLE	**Df Model:**	9
Date:	Mon, 16 Mar 2026	**Pseudo R-squ.:**	0.1402
Time:	04:58:10	**Log-Likelihood:**	-1.6811e+05
converged:	True	**LL-Null:**	-1.9552e+05
Covariance Type:	HC1	**LLR p-value:**	0.000

	coef	std err	z	P>|z|	[0.025	0.975]
const	-3.6492	0.568	-6.421	0.000	-4.763	-2.535
dti	2.3640	0.041	57.392	0.000	2.283	2.445
utilization	1.7410	0.033	52.953	0.000	1.677	1.805
past_due_30d_count	0.3363	0.004	83.028	0.000	0.328	0.344
income	-1.005e-05	2.44e-07	-41.169	0.000	-1.05e-05	-9.57e-06
salary_customer	-0.1909	0.009	-22.147	0.000	-0.208	-0.174
product_count	-0.0815	0.003	-25.325	0.000	-0.088	-0.075
policy_rate	0.0238	0.009	2.718	0.007	0.007	0.041
unemployment	0.0678	0.027	2.535	0.011	0.015	0.120
cpi_yoy	0.0011	0.006	0.191	0.849	-0.010	0.012

Odds Ratio ve Katsayıların Ekonomik Yorumu

Lojistik regresyon katsayıları log-odds cinsinden yorumlandığı için doğrudan sezgisel değildir. Bu nedenle katsayılar üstel dönüşümden geçirilerek odds ratio değerleri hesaplanmış ve değişkenlerin temerrüt odds'u üzerindeki etkisi daha yorumlanabilir hale getirilir:

In [28]:
```
params = logit_res_robust.params
conf = logit_res_robust.conf_int()
or_table = pd.DataFrame({
    "coef": params,
    "odds_ratio": np.exp(params),
    "ci_low_or": np.exp(conf[0]),
    "ci_high_or": np.exp(conf[1]),
    "pvalue":  logit_res_robust.pvalues
}).sort_values("pvalue")
```

In [29]:
```
or_table
```

Out[29]:

	coef	odds_ratio	ci_low_or	ci_high_or	pvalue
dti	2.364050	10.633931	9.809166	11.528044	0.000000e+00
utilization	1.740972	5.702884	5.346984	6.082474	0.000000e+00
past_due_30d_count	0.336326	1.399795	1.388725	1.410952	0.000000e+00
income	-0.000010	0.999990	0.999989	0.999990	0.000000e+00
product_count	-0.081517	0.921717	0.915920	0.927550	1.712032e-141
salary_customer	-0.190875	0.826236	0.812396	0.840311	1.127091e-108
const	-3.649169	0.026013	0.008539	0.079240	1.354582e-10
policy_rate	0.023774	1.024059	1.006654	1.041765	6.562929e-03
unemployment	0.067790	1.070140	1.015507	1.127714	1.122888e-02
cpi_yoy	0.001052	1.001053	0.990293	1.011930	8.486295e-01

Dti 1 birim artarsa şeklinde yorum yapmak mantıklı değildir zira dti 0-1 arasında değer alır bu sebeple Temerrüt olma ihtimalinin, temerrüt olmama ihtimaline oranı olan default odds değerini şöyle hesaplamak daha uygundur;

e^2.364×0.1 ≈ 1.27 ----> (Yüzde degişim = (OR−1)×100)

Yorum: DTI'daki 10 puanlık artış, temerrüt gerçekleşme odds'unu yaklaşık %27 artırıyor; bu da başlangıç risk seviyesine bağlı olarak temerrüt olasılığını anlamlı ölçüde yükseltiyor.

Örneğin başlangıç Riski (PD) %5 iken: Başlangıç Odds = 0.05 / 0.95 = 0.0526 --- Dti den kaynaklanan Yeni Odds: 0.0526 × 1.27 = 0.0668 Ve yeni PD için = 0.0668 / (1+0.0668) ≈ 0.0626 %5 ----> %6.26 yani artış 1.26 puan

%20 iken: Odds = 0.20 / 0.80 = 0.25 Yeni Odds = 0.25 × 1.27 = 0.3175 Yeni PD ≈ 0.241 %20 ----> %24.1 Artış 4.1 puan

---

Modelin Ayırma Gücü: AUC, ROC Eğrisi ve KS Metriği

AUC

AUC = Area Under the ROC Curve (ROC eğrisinin altında kalan alan)

AUC, modelin "iyi müşteri" ile "kötü müşteriyi" ayırma gücünü ölçer.

yani:

Model, rastgele seçilen bir temerrüt müşterisine rastgele seçilen sağlam müşteriden daha yüksek risk skoru verir mi? P(Default müştersinin skoru > Non-default müşterisinin skoru)

In [30]:
```
from sklearn.metrics import roc_auc_score

x_test = test[features]
x_test_const = sm.add_constant(x_test, has_constant="add")
test_pred = logit_res_robust.predict(x_test_const)          # eğitilmiş logit modelinin test setindeki her gözlem için ürettiğ

# Alternatif
# X_test = sm.add_constant(test[features], has_constant="add")
# test_pred = logit_res_robust.predict(X_test)

auc = roc_auc_score(test["default_12m"], test_pred) #test["default_12m"] gerçek sonuçlar
print("Test Auc:", auc)
```

```
Test Auc: 0.7460502480826692
```

Model, rastgele seçilen bir temerrüt müşterisine rastgele seçilen temerrütsüz müşteriden daha yüksek risk skoru verme olasılığı açısından yaklaşık %74.6'lık bir ayrıştırma gücüne sahip.

ROC eğrisini çizelim

In [31]:
```
from sklearn.metrics import roc_curve
import matplotlib.pyplot as plt

fpr, tpr, thresholds = roc_curve(test["default_12m"], test_pred)

plt.plot(fpr, tpr)
plt.plot([0,1],[0,1],'--')
plt.xlabel("False Positive Rate")
plt.ylabel("True Positive Rate")
plt.title("ROC Curve")
plt.show()
```

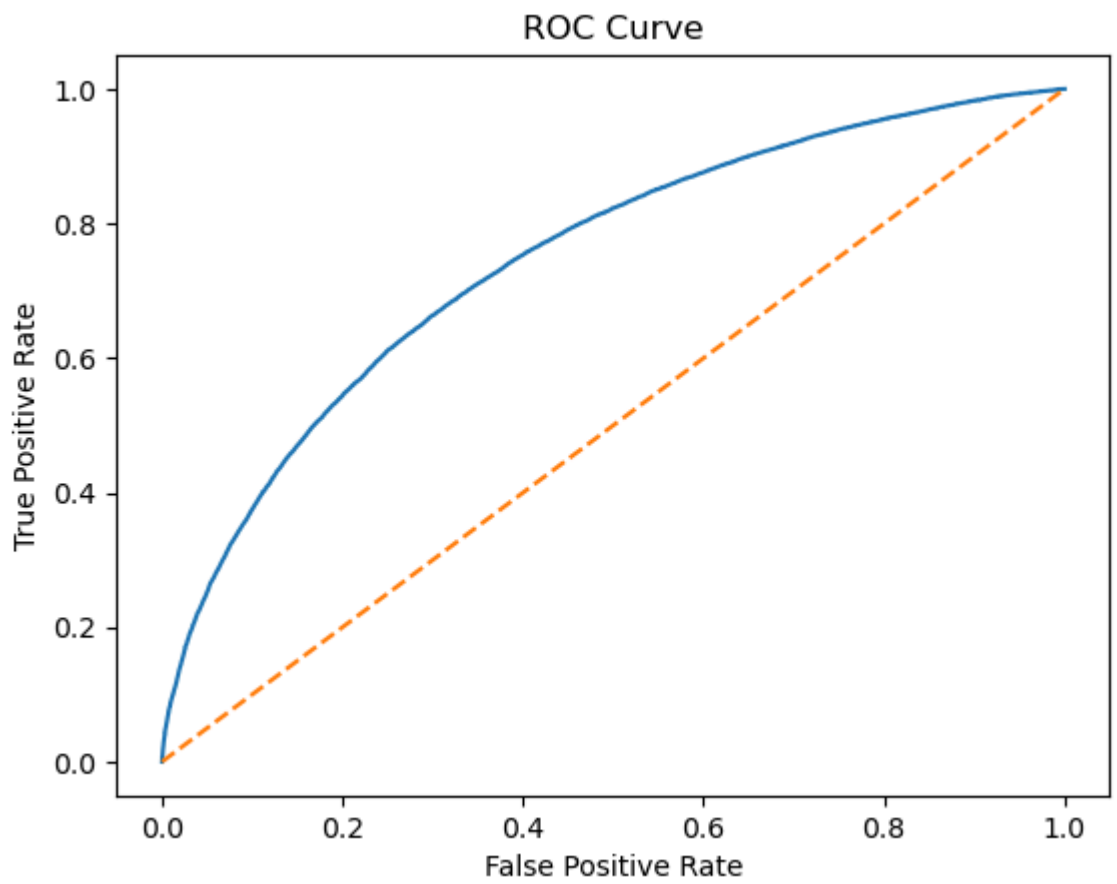

Kolmogorov–Smirnov (KS)

Kolmogorov–Smirnov (KS) istatistiği, modelin temerrüt eden ve etmeyen müşterileri ne kadar iyi ayırt edebildiğini ölçen bir performans metriğidir. KS değeri, temerrüt eden ve etmeyen müşteri gruplarının kümülatif dağılımları arasındaki maksimum farkı ifade eder.

KS	Yorum
< 0.2	Zayıf
0.2 – 0.3	Orta
0.3 – 0.4	İyi

In [32]:
```
from sklearn.metrics import roc_curve
import numpy as np

fpr, tpr, thresholds = roc_curve(test["default_12m"], test_pred)

ks = np.max(tpr - fpr)

print("KS:", ks)
```

```
KS: 0.3641575571237704
```

Model için hesaplanmış KS değeri yaklaşık **0.36** olarak bulundu. Risk modellemesinde KS değerinin 0.30 üzerinde olması modelin temerrüt eden ve etmeyen müşterileri ayırt etme konusunda iyi bir performans gösterdiğini söylüyor.

In [33]:
```
plt.plot(thresholds, tpr - fpr)
plt.title("KS Curve")
plt.show()
```

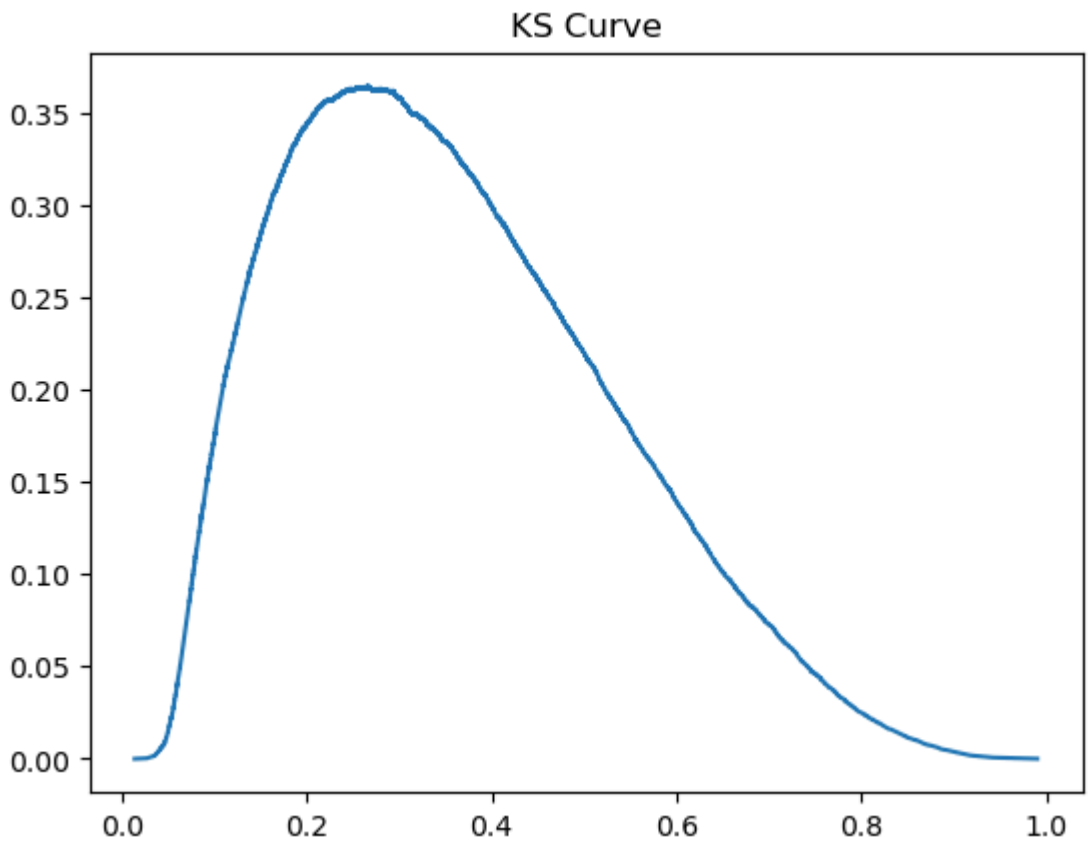

KS grafiğinde görülen maksimum fark noktası, modelin temerrüt eden ve etmeyen müşteri dağılımlarını en iyi ayırdığı eşiği temsil eder.

Risk Sıralama Performansı

Decile Analizi

En riskli diye işaretlediğim grup gerçekten daha mı çok temerrüt ediyor?

Decile analizi şunu gösterir:

PD'yi 10 gruba (decile) böl

Her grupta:

- ortalama PD (model ne diyor?)
- gerçekleşen default oranı (gerçek ne olmuş?)
- kaç kayıt var (istatistiki güven)

In [34]:
```
## 1) test_pred'i test tablosuna ekliyoruz (yeni bir kolon)
test = test.copy()   # orijinali bozmamak için kopya#
test["pd_pred"] = test_pred     # modelin PD tahminleri
```

In [35]:
```
# 2) pd_pred'i 10 eşit parçaya bölüyoruz (qcut = quantile cut)
# labels=False -> 0,1,2,...,9 olarak etiketler
test["decile"] = pd.qcut(test["pd_pred"], 10, labels=False)
```

In [36]:
```
# 3) her decile için özet tablo üretiyoruz
decile_table = (
    test.groupby("decile")
        .agg(
            count=("default_12m", "size"),  # kaç satır var?
            avg_pd=("pd_pred", "mean"),      # modelin ortalama PD'si
            default_rate=("default_12m","mean")  # gerçekleşen default oranı (Bernoulli değişkeninde mean oran'a eşit)
        )
        .sort_index()
)

decile_table
```

Out[36]:

decile	count	avg_pd	default_rate
0	9000	0.062802	0.064000
1	9000	0.091373	0.094000
2	9000	0.120695	0.125667
3	9000	0.153992	0.153222
4	9000	0.191860	0.190556
5	9000	0.236676	0.239556
6	9000	0.290960	0.292667
7	9000	0.359559	0.356222
8	9000	0.457662	0.455778
9	9000	0.648105	0.643667

Model riskli müşterileri olması gerektiği gibi yukarı doğru sıralamış. Decile yapısı düzgün. Üstelik kalibrasyon yapmamamıza rağmen model ile gerçekleşen değerler neredeyse birebir bunun sebebi sentetik verimizi Logit üretirken modelimizi de Logit olarak kurduk. Yani: Gerçek dünya ---> logit , Tahmin modeli ---> logit

Gerçek hayatta:

- Veri gürültülüdür
- Davranış dinamik değişir
- Ölçüm hatası vardır
- Değişkenler eksiktir
- Non-linear yapı vardır

In [37]:
```
#Buna rağmen modelin tahmin ettiği PD seviyelerinin gerçekleşen oranlarla ne ölçüde uyumlu olduğunu görmek amacıyla ayrıca kal
```

Kalibrasyon (Diagnostic)

In [38]:
```
import matplotlib.pyplot as plt

# 1) 10 bin (bin = aralık) yapıyoruz
test["pd_bin"] = pd.qcut(test["pd_pred"], 10, duplicates="drop")

cal_table = (
    test.groupby("pd_bin", observed = True)
        .agg(
            avg_pd=("pd_pred", "mean"),
            default_rate=("default_12m", "mean"),
            count=("default_12m", "size")
        )
)

# 2) Grafik: x=avg_pd, y=default_rate
plt.plot(cal_table["avg_pd"], cal_table["default_rate"], marker="o")
plt.plot([0, 1], [0, 1], "--")  # mükemmel kalibrasyon çizgisi
plt.xlabel("Tahmin edilen ortalama PD")
plt.ylabel("Gerçekleşen default oranı")
plt.title("Calibration Plot")
plt.show()

cal_table
```

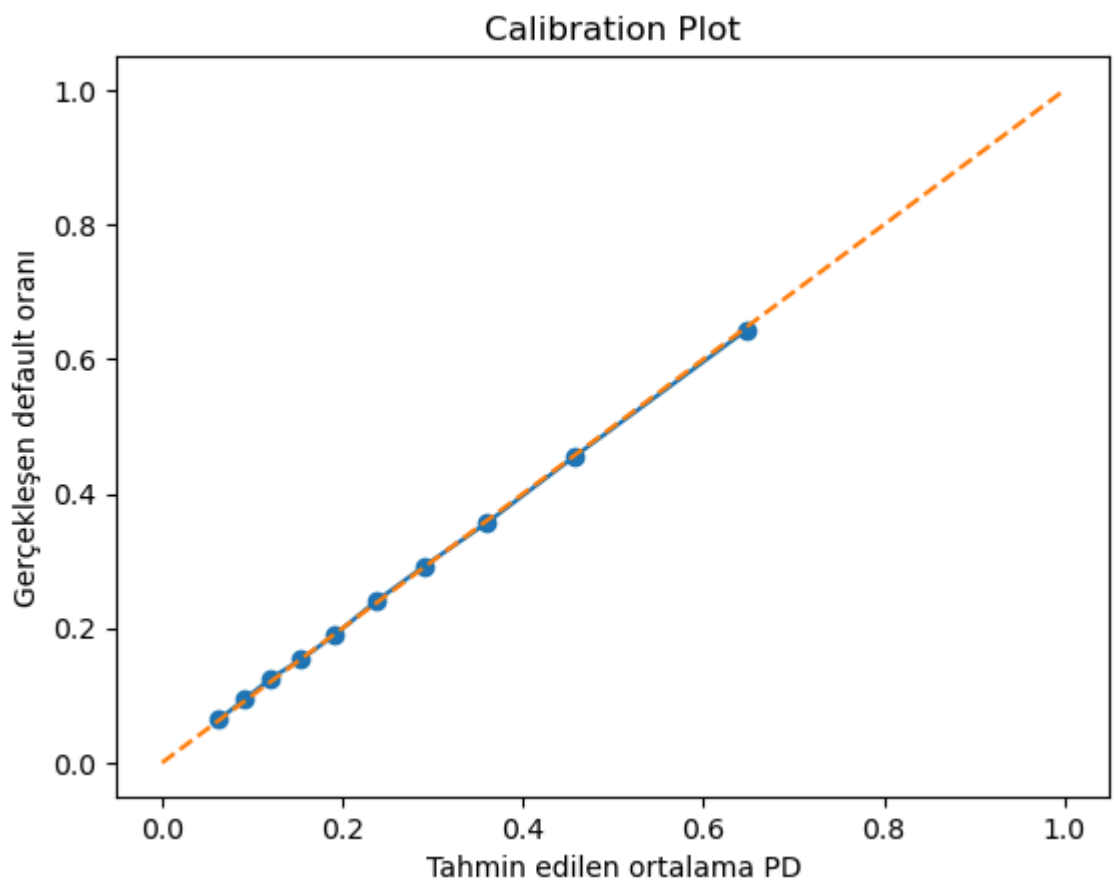

Out[38]:

pd_bin	avg_pd	default_rate	count
(0.013000000000000001, 0.078]	0.062802	0.064000	9000
(0.078, 0.105]	0.091373	0.094000	9000
(0.105, 0.136]	0.120695	0.125667	9000
(0.136, 0.172]	0.153992	0.153222	9000
(0.172, 0.213]	0.191860	0.190556	9000
(0.213, 0.262]	0.236676	0.239556	9000
(0.262, 0.322]	0.290960	0.292667	9000
(0.322, 0.401]	0.359559	0.356222	9000
(0.401, 0.524]	0.457662	0.455778	9000
(0.524, 0.99]	0.648105	0.643667	9000

Stabilite ve Backtesting Analizi

Aylık AUC

In [39]:
```
t = test.copy()
t["pd_pred"] = test_pred

monthly_auc = (
    t.groupby("month")[["default_12m","pd_pred"]]
     .apply(lambda df: roc_auc_score(df["default_12m"], df["pd_pred"]))
     .reset_index(name="auc")   #Bu index'i normal sütun yapar
     .sort_values("month")
)

monthly_auc     # Dalgalanmalara bakarız: max(AUC)-min(AUC) => <0.03 → iyi  0.03–0.05 → izlenmeli 0.05 → alarm
```

Out[39]:

	month	auc
0	2025-08-01	0.741543
1	2025-09-01	0.744792
2	2025-10-01	0.743730
3	2025-11-01	0.746374
4	2025-12-01	0.753798

In [40]:
```
plt.plot(monthly_auc["month"], monthly_auc["auc"], marker="o")
plt.xticks(rotation=45)
plt.ylim(0.5, 1.0) # Model stabilite grafiklerinde y-ekseni dar tutulursa küçük değişimler abartılı görünür, yönetim sunumları
plt.xlabel("Ay")
plt.ylabel("AUC")
plt.title("Monthly AUC (Stability / Backtesting)")
plt.show()
```

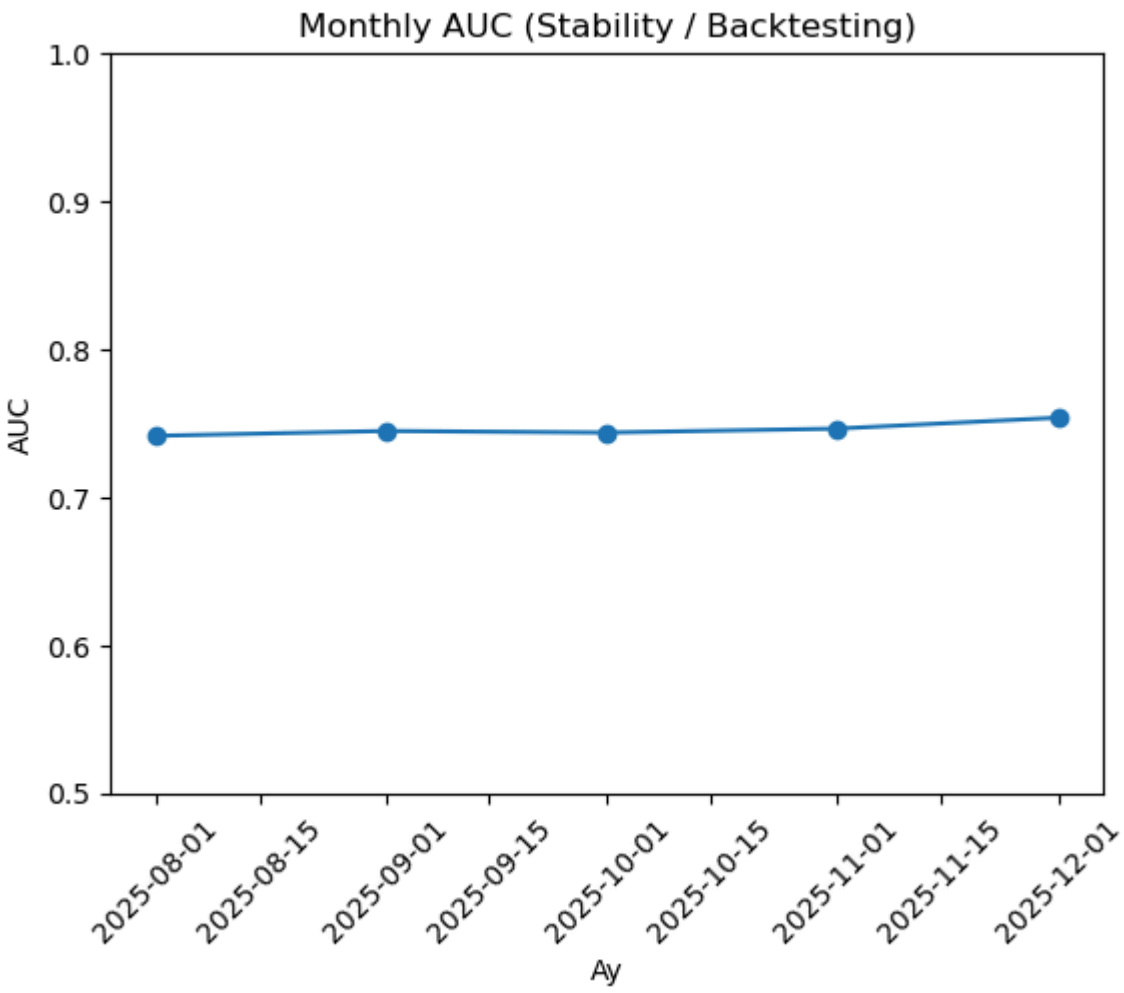

Aylık Kalibrasyon Analizi

In [41]:
```
# Modelin söylediği risk oranı avg_pd gerçek default oranına yakın mı ?

monthly_cal = (
    t.groupby("month")
     .agg(
         avg_pd=("pd_pred", "mean"),
         default_rate=("default_12m", "mean"),
         n=("default_12m", "size")
     )
    .reset_index()
    .sort_values("month")
)

monthly_cal
```

Out[41]:

	month	avg_pd	default_rate	n
0	2025-08-01	0.259948	0.262167	18000
1	2025-09-01	0.262607	0.260556	18000
2	2025-10-01	0.262468	0.261889	18000
3	2025-11-01	0.261982	0.263167	18000
4	2025-12-01	0.259837	0.259889	18000

Eşik Seçimi (Cut-off) Analizi ve Confusion Matrix

Şimdiye kadar:

- Model sıralıyor mu? (AUC/decile)
- PD'ler gerçekçi mi? (kalibrasyon)

Artık iş sorusu şu:

- Hangi PD üstünü riskli sayalım?

Confusion matrix nasıl okunur?

- TN: Gerçekte temerrüt etmeyen ve model tarafından doğru şekilde risksiz sınıflanan müşteri
- FP: Gerçekte temerrüt etmeyen ancak model tarafından riskli sınıflanan müşteri
- FN: Gerçekte temerrüt eden ancak model tarafından kaçırılan müşteri (bankada pahalı)
- TP: Gerçekte temerrüt eden ve model tarafından doğru şekilde riskli sınıflanan müşteri

Bankacılıkta genelde FN maliyeti daha ağırdır.

[[TN FP]

[FN TP]]

In [42]:
```
from sklearn.metrics import confusion_matrix, classification_report

def evaluate_threshold(th):
    pred_class = (test["pd_pred"] >= th).astype(int)

    cm = confusion_matrix(test["default_12m"], pred_class)

    print("Threshold:", th)
    print("Confusion Matrix:\n", cm)
    print(classification_report(test["default_12m"], pred_class, digits=3))
    print("-"*40)

for th in [0.05, 0.10, 0.15, 0.20]:
    evaluate_threshold(th)
```

```
Threshold: 0.05
Confusion Matrix:
 [[ 1122 65340]
 [   55 23483]]
              precision    recall  f1-score   support

           0      0.953     0.017     0.033     66462
           1      0.264     0.998     0.418     23538

    accuracy                          0.273     90000
   macro avg      0.609     0.507     0.226     90000
weighted avg      0.773     0.273     0.134     90000

----------------------------------------
Threshold: 0.1
Confusion Matrix:
 [[15012 51450]
 [ 1243 22295]]
              precision    recall  f1-score   support

           0      0.924     0.226     0.363     66462
           1      0.302     0.947     0.458     23538

    accuracy                          0.415     90000
   macro avg      0.613     0.587     0.411     90000
weighted avg      0.761     0.415     0.388     90000

----------------------------------------
Threshold: 0.15
Confusion Matrix:
 [[27483 38979]
 [ 3070 20468]]
              precision    recall  f1-score   support

           0      0.900     0.414     0.567     66462
           1      0.344     0.870     0.493     23538

    accuracy                          0.533     90000
   macro avg      0.622     0.642     0.530     90000
weighted avg      0.754     0.533     0.547     90000

----------------------------------------
Threshold: 0.2
Confusion Matrix:
 [[37253 29209]
 [ 5107 18431]]
              precision    recall  f1-score   support

           0      0.879     0.561     0.685     66462
           1      0.387     0.783     0.518     23538

    accuracy                          0.619     90000
   macro avg      0.633     0.672     0.601     90000
weighted avg      0.751     0.619     0.641     90000

----------------------------------------
```

Model eşik arttıkça yanlış alarm oranını azaltmakta, ancak riskli müşteri yakalama oranı düşmektedir. 0.15–0.20 aralığı precision–recall dengesi açısından optimum operasyonel bölge olarak görünmektedir. Risk ekipleri yanlış alarmı tolere eder, ama kaçırılmış default'u tolere etmez.

- Class 0 için precision : Modelin risksiz dediği müşterilerin kaç tanesi gerçekten risksiz?
- Class 0 için recall : Gerçekte risksiz olan müşterilerin kaçını model doğru şekilde risksiz olarak yakaladı?
- Class 1 için precision : Modelin riskli dediği müşterilerin kaç tanesi gerçekten riskli?

- Class 1 için recall : Gerçekte temerrüt eden müşterilerin kaçını model yakalayabildi?

Threshold = 0.2 iken model, temerrüt eden müşterilerin yaklaşık %78'ini yakalayabilmekte (recall ≈ 0.78), ancak riskli olarak işaretlenen müşterilerin %38'i gerçekten risklidir (precision ≈ 0.39). Bu sonuçlar modelin erken uyarı amacıyla kullanılabilecek seviyede bir yakalama kapasitesine sahip olduğunu göstermektedir.

Watchlist Yaklaşımı

__Bankacılıkta threshold yerine Top X% tercih edilir peki neden ?__

- Operasyon kapasitesi sabittir.
- Risk ekibi ayda belirli sayıda müşteri inceleyebilir
- Precision ve Recall tek başına karar verdirmez

  Bu sebeple:

- Model kim daha riskli diye sıralar
- İş birimi kaç kişiyle aksiyon alabilirz der ve Top X% seçilir.

__Watchlist Seçimi__

Test veri setimizde 90000 müşteri

Varsayalım ki risk ekibi kapsitemiz de ayda 9000 müşteri

Yani:

- En riskli %10 watchlist'e girer

In [43]:
```
watch = test.copy()
watch["pd_pred"] = test_pred

watch = watch.sort_values("pd_pred", ascending = False) #en riskli üstte olacak şekilde sıraladık ve sıralamayı kaydettik
```

In [44]:
```
# Risk rank'ı oluştururuz. Kişi risk sıralamasında kaçıncı yüzdelikte?

watch["risk_rank_pct"] = (
    watch["pd_pred"].rank(method="first", pct=True)
)

# 0 --> en düşük risk, 1--> en yüksek risk
```

In [45]:
```
# En riskli %10 seçelim

watchlist = watch[watch["risk_rank_pct"] >= 0.90]
```

Watchlist Performansı: Capture Rate ve Lift

In [46]:
```
# Capture Rate (çok kritik)
# Default olan müşterilerin kaçını watchlist yakalıyor?

total_defaults = watch["default_12m"].sum()
captured_default = watchlist["default_12m"].sum()
capture_rate = captured_default / total_defaults

print("Capture Rate:", capture_rate)
```

```
Capture Rate: 0.2461551533690203
```

In [47]:
```
# Lift Metric

watch_dr = watch["default_12m"].mean()
watchlist_dr = watchlist["default_12m"].mean()
lift = watchlist_dr / watch_dr

print("Lift:", lift)
```

```
Lift: 2.4612780583503864
```

Capture (@Top10%)	Yorum
~10%	random (kötü)
15–20%	kabul
20–30%	iyi

Capture (@Top10%)	Yorum
30%+	güçlü

Model tarafından oluşturulan watchlist, toplam temerrütlerin %24.6'sını yakalarken, genel portföye kıyasla 2.46 kat daha yüksek risk yoğunluğu göstermektedir.

Capture Curve ve Lift Curve

In [48]:
```
# Capture Curve (Risk ekibi kaç müşteri işlerse kaç default yakalar)
```

In [49]:
```
watch_curve = watch.copy()

watch_curve = watch_curve.sort_values("pd_pred", ascending = False).reset_index(drop=True)  # yüksek risk üstte

total_defaults = watch_curve["default_12m"].sum()

watch_curve["cum_defaults"] = watch_curve["default_12m"].cumsum()                          # sıralı kümülatif default
watch_curve["cum_population_pct"] = (np.arange(1, len(watch_curve)+1))/len(watch_curve)     # yüzde olarak müşteri oranı
watch_curve["capture_rate"] = watch_curve["cum_defaults"] / total_defaults                  # capture rate
```

In [50]:
```
base_dr = watch_curve["default_12m"].mean()

watch_curve["cum_default_rate"] = watch_curve["cum_defaults"] / (np.arange(1, len(watch_curve)+1))    # kümülatif sıralı defau
watch_curve["lift"] = watch_curve["cum_default_rate"] / base_dr                                        # kümülatif lift
```

In [51]:
```
# Grafikte görelim

#Capture Curve

plt.plot(watch_curve["cum_population_pct"], watch_curve["capture_rate"])
plt.plot([0,1],[0,1],"--")
plt.xlabel("Portföyün seçilen yüzdesi")
plt.ylabel("Yakalanan default oranı")
plt.title("Capture Curve (Cumulative Gains)")
plt.show()

# lift Curve

plt.plot(watch_curve["cum_population_pct"], watch_curve["lift"])
plt.xlabel("Portföyün seçilen yüzdesi")
plt.ylabel("Lift")
plt.title("Lift Curve")
plt.show()
```

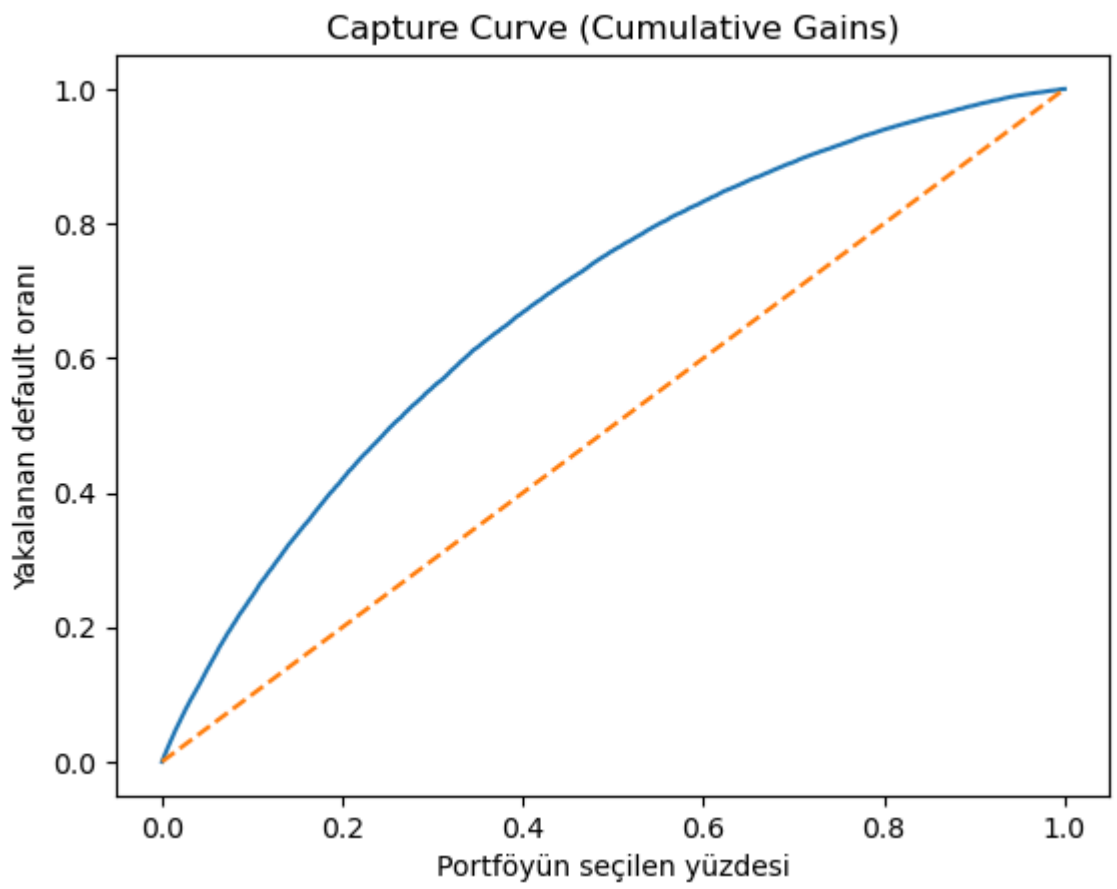

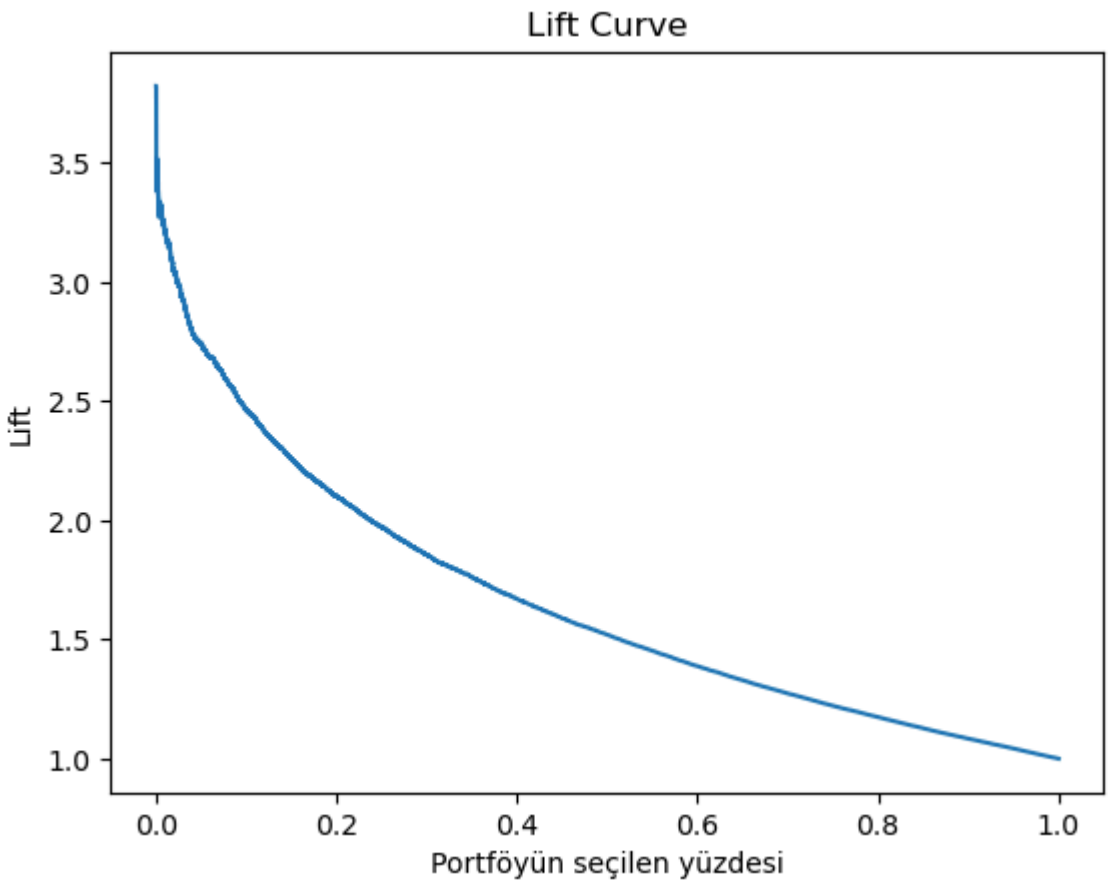

Capture Curve: Eğri ne kadar yukarıdaysa model o kadar iyi. Düz çizgi random seçim.

Lift Curve: Başlangıçta yüksek olur. Sonra düşer. 1'e yaklaşır (rastgelelik)

Capture curve'in şekli şunu gösteriyor:

İlk %10 çok değerli, %20 sonrası marjinal kazanç azalıyor.

Azalan Marjinal Getiri

Yani: Liste büyüdükçe yakalanan ek temerrüt sayısı artmakla birlikte, her ilave müşteri grubunun sağladığı marjinal katkı giderek azalmaktadır.

__Gerçek bankacılık segmentasyonu__

- Tek watchlist yok

Segment	PD	Aksiyon
Green	düşük	normal izleme
Amber	orta	SMS / hafif aksiyon
Red	yüksek	arama / collection

Early Warning Segment Tasarımı

Risk Sıralaması

In [52]:
```
seg = watch.copy()

seg = seg.sort_values("pd_pred", ascending=False).reset_index(drop=True) # Yüksek risk üstte
```

Percentile Oluşturma

In [53]:
```
seg["risk_pct"] = seg["pd_pred"].rank(method="first", pct=True)  # rank / toplam_satır
```

Segmentleri Tanımlama

In [54]:
```
def assign_segment(x):
    if x >= 0.95:
        return "RED"
    elif x >= 0.80:
        return "AMBER"
    else:
        return "GREEN"

seg["segment"] = seg["risk_pct"].apply(assign_segment)
```

Segment Performansı Ölçme

In [55]:
```
segment_table = (
    seg.groupby("segment")
       .agg(
           count=("default_12m","size"),
```

```
            avg_pd=("pd_pred","mean"),
            default_rate=("default_12m","mean")
        )
        .sort_values("avg_pd", ascending=False)
)

segment_table
```

Out[55]:

segment	count	avg_pd	default_rate
RED	4501	0.724512	0.716952
AMBER	13500	0.495651	0.493926
GREEN	71999	0.188487	0.189489

Segment bazında tahmin edilen ortalama PD ile gerçekleşen temerrüt oranlarının aynı yönlü ve artan yapıda olması, modelin operasyonel segmentasyon amacı için uygun olduğunu göstermektedir. RED, AMBER ve GREEN segmentleri risk seviyelerini anlamlı biçimde ayrıştırmaktadır.

Model Özeti

In [56]:

```
summary = {
    "Metrik": [
        "Model Türü",
        "Hedef",
        "Gözlem Sayısı",
        "Test AUC",
        "Watchlist Büyüklüğü",
        "Capture Rate @Top10%",
        "Lift @Top10%",
    ],
    "Değer": [
        "Lojistik Regresyon",
        "Önümüzdeki 12 ay içinde temerrüt",
        len(test),
        auc,
        "Top 10%",
        capture_rate,
        lift
    ]
}

summary_df = pd.DataFrame(summary)
summary_df
```

Out[56]:

	Metrik	Değer
0	Model Türü	Lojistik Regresyon
1	Hedef	Önümüzdeki 12 ay içinde temerrüt
2	Gözlem Sayısı	90000
3	Test AUC	0.74605
4	Watchlist Büyüklüğü	Top 10%
5	Capture Rate @Top10%	0.246155
6	Lift @Top10%	2.461278

Segment Stratejisi

In [57]:

```
segment_policy = pd.DataFrame({
    "Segment": ["RED", "AMBER", "GREEN"],
    "Portföy Payı %": ["Top 5%", "5–20%", "Kalan"],
    "Önerilen Aksiyon": [
        "Proaktif arama / tahsilat aksiyonu",
        "SMS / ödeme hatırlatma",
        "Normal izleme"
    ]
})

segment_policy
```

Out[57]:

	Segment	Portföy Payı %	Önerilen Aksiyon
0	RED	Top 5%	Proaktif arama / tahsilat aksiyonu
1	AMBER	5–20%	SMS / ödeme hatırlatma
2	GREEN	Kalan	Normal izleme

Her müşteri için model bir temerrüt olasılığı (Probability of Default – PD) tahmin eder. Müşteriler PD değerlerine göre sıralanır ve operasyonel izleme listelerine (watchlist) ayrılır.

- En üst %5'lik dilim (KIRMIZI segment) en yüksek riskli müşterileri içerir ve hemen tahsilat aksiyonlarını tetikler.
- %5–%20 aralığındaki müşteriler (AMBER segment) için SMS hatırlatmaları gibi erken uyarı müdahaleleri uygulanır.
- Kalan müşteriler ise proaktif bir müdahale olmadan yalnızca izleme kapsamında takip edilir.

Model Kısıtları

- Veri seti sentetiktir ve gerçek banka portföylerini temsil etmemektedir.
- Makroekonomik değişkenler simüle edilmiştir.
- Temerrüt tanımı, yalnızca 30 gün gecikme olarak basitleştirilmiştir.
- Gerçek bankacılık verilerindeki davranışsal gürültü ve operasyonel kısıtlar sınırlı ölçüde temsil edilmektedir.

Genel Sonuç

Bu çalışma kapsamında perakende bankacılık kredi portföyü için 12 aylık temerrüt olasılığını tahmin eden bir erken uyarı modeli geliştirilmiştir. Model; ayrıştırma gücü, kalibrasyon, zaman içi stabilite ve operasyonel segmentasyon açısından tatmin edici sonuçlar vermiştir. Elde edilen bulgular, modelin watchlist oluşturma ve risk önceliklendirme süreçlerinde kullanılabilecek nitelikte olduğunu göstermektedir.

In [ ]:

```
```